2025

R-kielen opas

ASIANTUNTIJALUENNOT
BRAGGE JANNE TTM23SAI

Table of Contents

Johdanto

Mikä on R-kieli?

R on avoimen lähdekoodin ohjelmointikieli, joka on erityisesti suunniteltu tilastolliseen laskentaan ja datan analysointiin. Se on suosittu erityisesti akateemisessa maailmassa, datatieteessä, tilastotieteessä ja koneoppimisessa. R:n vahvuudet ovat sen monipuoliset datan käsittely- ja visualisointityökalut sekä laaja yhteisö, joka kehittää jatkuvasti uusia paketteja ja resursseja.

Kenelle tämä opas on tarkoitettu?

Tämä opas on suunniteltu kaikille, jotka haluavat oppia R-ohjelmointia ja käyttää sitä datan käsittelyyn, analyysiin ja visualisointiin. Se sopii erityisesti:

- **Aloittelijoille**, jotka eivät ole aiemmin ohjelmoineet.
- **Tilastotieteilijöille** ja **data-analyytikoille**, jotka haluavat hyödyntää R:ää työssään.
- **Data Scientists** -ammattilaisille, jotka haluavat hallita R:n vahvuuksia datan manipuloinnissa ja visualisoinnissa.

Miksi oppia R-kieltä?

R tarjoaa lukuisia etuja datan käsittelyyn ja analysointiin:

1. **Monipuolisuus**
   R tukee sekä yksinkertaisia laskelmia että monimutkaisia tilastollisia malleja ja koneoppimisalgoritmeja.
2. **Tehokkaat visualisointityökalut**
   R:llä voi luoda korkealaatuisia kaavioita, jotka tekevät datasta helppotajuisempaa.
3. **Laaja pakettivalikoima**
   CRAN-arkistossa on tuhansia paketteja, jotka laajentavat R:n ominaisuuksia eri tarkoituksiin.
4. **Yhteisön tuki**
   R:n käyttäjillä on aktiivinen yhteisö ja runsaasti resursseja, kuten oppaita, foorumeita ja verkkokursseja.

Mitä opas kattaa?

Tämä opas tarjoaa perusteellisen johdatuksen R-kieleen ja sen soveltamiseen datatieteessä. Opas etenee loogisessa järjestyksessä:

1. **Muuttujat ja tietotyypit**
   Opi R:n perusrakenteet, kuten vektorit, listat, matriisit ja dataframet.
2. **Ohjausrakenteet ja funktiot**
   Hallitse ohjelmoinnin perusperiaatteet ehtolauseilla, silmukoilla ja funktioilla.
3. **Datamanipulaatio**
   Opi muokkaamaan ja järjestelemään dataa sekä hyödyntämään dplyr- ja tidyr-paketteja tehokkaaseen analyysiin.
4. **Datavisualisointi**
   Sukella visuaalisuuden maailmaan ja opi luomaan kauniita kaavioita ggplot2-kirjastolla.
5. **Käytännön esimerkit**
   Sovella opittuja taitoja todellisiin ongelmiin, kuten myyntianalyysiin ja tilastollisiin laskelmiin.

Miten käyttää tätä opasta?

- Aloita perusteista ja etene järjestyksessä, erityisesti jos olet uusi ohjelmoinnissa.
- Kokeile kaikkia esimerkkejä itse. RStudio on suositeltu ympäristö harjoitteluun.
- Hyödynnä käytännön esimerkkejä ja sovella niitä omiin projekteihisi.
- Palaa oppaan osioihin aina tarvittaessa, sillä se toimii myös viitekirjana.

Mitä opas ei kata?

Vaikka tämä opas tarjoaa kattavan perustan, se ei mene syvälle erityisaloihin, kuten koneoppimiseen tai biostatistiikkaan. Näille aiheille suositellaan erikoistuneita oppaita.

Tavoite

Oppaan tavoitteena on antaa sinulle käytännön taidot R-kielen hyödyntämiseen datan analysoinnissa ja visualisoinnissa. Opit soveltamaan R:ää tehokkaasti työssäsi ja projekteissasi.

Tervetuloa oppimaan R-ohjelmointia!

R-kielen Asentaminen

Tässä raportissa kuvataan vaiheittain, kuinka asentaa R-kieli ja siihen liittyvät työkalut (RStudio) Windows-, MacOS- ja Linux-käyttöjärjestelmissä.

---

1. R-kieli

R on avoimen lähdekoodin ohjelmointikieli, joka on erityisen suosittu data-analyysissä ja tilastollisessa laskennassa.

1.1. Windows

1. Siirry R:n viralliselle verkkosivustolle: CRAN R Project.
2. Valitse “Download R for Windows”.
3. Klikkaa "base" ja lataa viimeisin versio ("Download R X.X.X for Windows").
4. Suorita ladattu asennustiedosto.
    - Valitse asennuksen aikana oletusasetukset, ellet tiedä tarvitsevasi erityisiä määrittelyjä.
5. Kun asennus on valmis, R voidaan avata joko komentoriviltä tai RStudion kautta.

1.2. MacOS

1. Siirry CRAN-sivustolle: CRAN R Project.
2. Valitse “Download R for macOS”.
3. Lataa sopiva versio (yleensä "arm64.pkg" tai "x86_64.pkg" riippuen prosessoristasi).
4. Avaa ladattu tiedosto ja noudata ohjeita asentaaksesi R:n.
5. R on nyt käytettävissä. Asenna RStudio lisämukavuuden saavuttamiseksi.

1.3. Linux

1. Avaa komentorivi.
2. Lisää CRAN:n pakettivarasto järjestelmääsi. Esimerkiksi Ubuntu/Debian-järjestelmissä:
3. sudo apt update
4. sudo apt install r-base
5. Asenna tarvittaessa ylimääräiset paketit komennolla install.packages() R-konsolissa.
6. Käynnistä R kirjoittamalla komentoriville R.

---

2. RStudio-työkalun asentaminen

RStudio on R:n kehitysympäristö, joka tarjoaa helppokäyttöisen käyttöliittymän ja monipuolisia ominaisuuksia.

1. Siirry RStudion verkkosivustolle: RStudio Download.
2. Lataa ilmainen versio, joka on saatavilla kaikille käyttöjärjestelmille.
3. Asenna ohjelma ja avaa se. Varmista, että R on asennettu ennen RStudion käyttämistä.

---

3. Testaa asennus

1. Avaa R tai RStudio.
2. Kirjoita konsoliin:
3. print("R toimii oikein!")

Jos saat tulosteena tekstin "R toimii oikein!", asennus on onnistunut.

---

4. Lisäpakettien asentaminen

Voit lisätä R:ään laajennuksia (paketteja), jotka tarjoavat uusia toimintoja:

install.packages("dplyr")

library(dplyr)

Tämä komento asentaa ja lataa dplyr-paketin käyttöön.

---

5. Vinkkejä ja huomioitavaa

- **Päivitykset:** Pidä R ja RStudio ajan tasalla uusien ominaisuuksien ja parannusten vuoksi.
- **RMarkdown:** Asenna rmarkdown-paketti raporttien luomiseen:
- install.packages("rmarkdown")
- **Dokumentaatio:** Hyödynnä R:n laajaa verkkodokumentaatiota ja yhteisön resursseja.

Raportin avulla voit suorittaa R:n ja siihen liittyvien työkalujen asennuksen onnistuneesti eri käyttöjärjestelmissä.

Käytön aloittaminen

Pseudo-datasetin luominen

---

1. Avaa RStudio

- Käynnistä RStudio tietokoneellasi.

---

2. Luo uusi skriptitiedosto

1. Valitse ylävalikosta **File > New File > R Script**.
2. Uusi tyhjä R-skriptitiedosto avautuu editoriin.

---

3. Tallenna tiedosto

1. Klikkaa ylävalikosta **File > Save** tai paina **Ctrl + S** (Windows) tai **Cmd + S** (Mac).
2. Anna tiedostolle nimi, esimerkiksi:
   pseudo_dataset.R
3. Valitse tallennuspaikka ja paina **Save**.

---

4. Aloita koodin kirjoittaminen

Esimerkki pseudodatasetin luomisesta:

```
# Tämä on uusi R-tiedosto
set.seed(123)
pseudo_data <- data.frame(
 ID = 1:50,
 Value = rnorm(50, mean = 100, sd = 15)
)
print(head(pseudo_data))
View(pseudo_data)
```

---

5. Suorita koodi

1. Valitse haluamasi koodirivi tai lohko.
2. Paina **Ctrl + Enter** (Windows) tai **Cmd + Enter** (Mac) suorittaaksesi sen.

Pseudodatan visualisointi

RStudiossa pseudodatan visualisointi onnistuu helposti esimerkiksi **ggplot2**-kirjastolla, joka on yksi suosituimmista R:n visualisointikirjastoista. Tässä on vaiheittainen ohje, kuinka voit visualisoida pseudodatan.

Esimerkki pseudodatan luomisesta ja visualisoinnista

1. Luo pseudodata

Aloitetaan yksinkertaisella pseudodatasetillä:

```
# Lataa ggplot2-kirjasto (asennus: install.packages("ggplot2"))
library(ggplot2)

# Luo pseudodata
set.seed(123)
pseudo_data <- data.frame(
 ID = 1:100,
 Age = sample(18:65, 100, replace = TRUE),
 Income = round(rnorm(100, mean = 50000, sd = 10000), 0),
 Gender = sample(c("Male", "Female"), 100, replace = TRUE)
)

# Tarkastele dataa
head(pseudo_data)
```

---

2. Perusvisualisointi: pistekaavio

Visualisoidaan esimerkiksi **ikä ja tulot sukupuolen mukaan**:

```
ggplot(pseudo_data, aes(x = Age, y = Income, color = Gender)) +
 geom_point(size = 3, alpha = 0.7) +  # Lisää pisteet
 labs(
  title = "Income vs Age by Gender",
  x = "Age",
  y = "Income"
```

```
) +
 theme_minimal()  # Käytä minimalistista teemaa
```

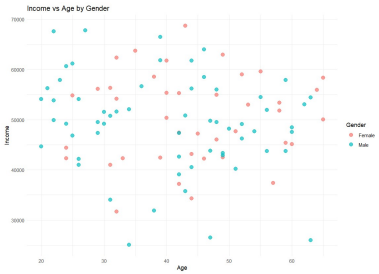

3. Histogrammi

Histogrammin avulla voit tarkastella esimerkiksi ikäjakaumaa:

```
ggplot(pseudo_data, aes(x = Age, fill = Gender)) +
 geom_histogram(binwidth = 5, alpha = 0.7, position = "dodge") +  # Histogrammi sukupuolen mukaan
 labs(
  title = "Age Distribution by Gender",
  x = "Age",
  y = "Count"
 ) +
 theme_minimal()
```

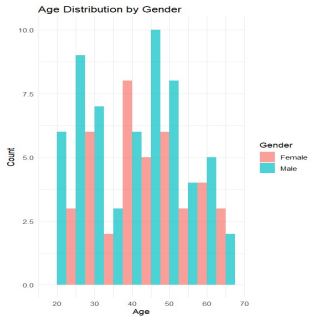

4. Laatikkokaavio (Boxplot)

Laatikkokaavio sopii hyvin tulojen jakauman tarkasteluun sukupuolen mukaan:

```
ggplot(pseudo_data, aes(x = Gender, y = Income, fill = Gender)) +
 geom_boxplot() +
 labs(
  title = "Income Distribution by Gender",
  x = "Gender",
  y = "Income"
 ) +
 theme_minimal()
```

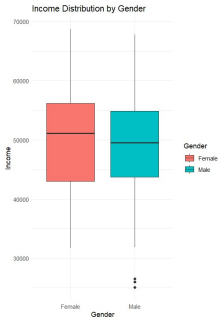

5. Viivakaavio (jos aikasarjadatan tyyppistä)

Jos sinulla olisi aikasarja, voit visualisoida sen näin:

```
pseudo_data$Time <- seq.Date(from = as.Date("2023-01-01"), by = "day", length.out = 100)

ggplot(pseudo_data, aes(x = Time, y = Income, color = Gender)) +
 geom_line() +
 labs(
  title = "Income Trend Over Time",
  x = "Time",
  y = "Income"
 ) +
 theme_minimal()
```

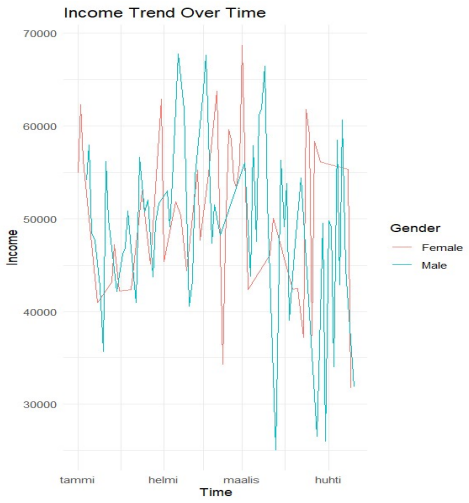

Vinkkejä

1. **Mukauta visualisointeja**:
   Lisää teemaa, värejä tai fontteja oman tarpeesi mukaan käyttämällä theme()-funktiota.
2. **Tallentaminen**:
   Tallenna visualisointi tiedostoksi:
3. g <- ggplot(pseudo_data, aes(x = Age, y = Income, color = Gender)) +
4. geom_point(size = 3, alpha = 0.7) +
5. labs(title = "Income vs Age by Gender", x = "Age", y = "Income") +
6. theme_minimal()
7.
8. ggsave("income_vs_age.png", plot = g, width = 8, height = 6)

Muuttujat (Variables)

Kappale 2: R-kielen muuttujat (Variables)

Mikä on muuttuja?

Muuttuja on nimetty säilö, joka tallentaa arvoja, kuten numeroita, tekstiä, loogisia arvoja tai muita tietotyyppejä. R-kielessä muuttujien avulla voimme tallentaa, muokata ja käyttää tietoja ohjelmoinnissa.

Muuttujien luonti

Muuttuja luodaan käyttämällä **<-**-operaattoria tai yhtälailla **=**-operaattoria.

Esimerkkejä:

Muuttujan luonti

x <- 10 # Luvun tallentaminen muuttujaan x

y = "Hello" # Merkkijonon tallentaminen muuttujaan y

z <- TRUE # Loogisen arvon tallentaminen muuttujaan z

Voit myös tarkistaa muuttujan arvon kirjoittamalla sen nimen:

x # Tulostaa: 10

y # Tulostaa: "Hello"

z # Tulostaa: TRUE

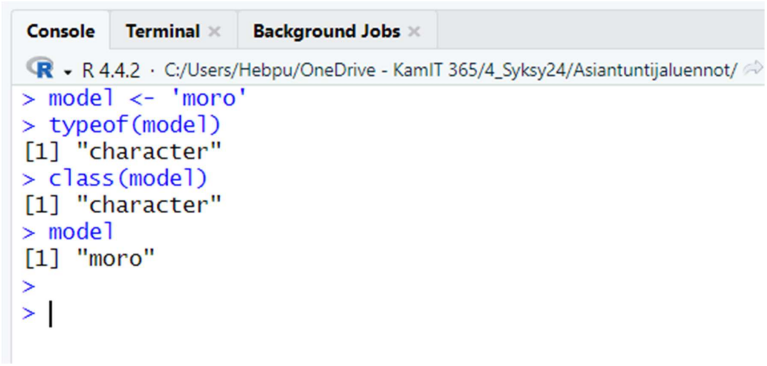

Muuttujien nimeäminen

R-kielessä muuttujien nimet voivat sisältää kirjaimia, numeroita, alaviivoja (_) ja pisteitä (.), mutta niiden on aloitettava kirjaimella tai pisteellä, joka ei seuraa numeroa.

Hyviä käytäntöjä:

- Käytä kuvaavia nimiä, kuten age tai total_sales.
- Noudatetaan **snake_case** tai **camelCase**-tyylejä:
    - **snake_case**: total_sales
    - **camelCase**: totalSales

Esimerkkejä:

valid_variable <- 5 # Sallittu

variable.name <- "text" # Sallittu

total_sales <- 200 # Sallittu

Virheelliset nimet:

2variable <- 5 # Ei sallittu (ei voi alkaa numerolla)

variable-name <- 5 # Ei sallittu (viiva ei ole sallittu merkki)

Muuttujatyypit

Muuttuja voi sisältää monentyyppisiä tietoja. Tässä yleisimmät tietotyypit:

1. **Numerot (numeric)**
   Esimerkiksi desimaaliluvut tai kokonaisluvut.
2. a <- 42 # Kokonaisluku
3. b <- 3.14 # Desimaaliluku
4. **Merkkijonot (character)**
   Tekstiä, jonka ympärillä käytetään lainausmerkkejä.
5. text <- "Hello, R!" # Merkkijono
6. **Loogiset arvot (logical)**
   Arvot **TRUE** tai **FALSE**.
7. is_active <- TRUE
8. **Vektorit (vector)**
   Useiden arvojen lista, kuten [1, 2, 3].
9. numbers <- c(1, 2, 3, 4, 5)

huom!

```
> num <- 43
> typeof(num)
[1] "double"
> num <- 43L
> typeof(num)
[1] "integer"
>
```

Muuttujien muuttaminen

Muuttuja voidaan päivittää helposti antamalla sille uusi arvo:

x <- 10 # Alkuperäinen arvo

x <- x + 5 # Päivitetään arvo (x nyt 15)

Muuttujan tyyppi voi myös vaihtua:

x <- "text" # x oli aiemmin numero, nyt se on merkkijono

Muuttujien käyttäminen laskutoimituksissa

Muuttujia voidaan käyttää laskutoimituksissa ja muissa operaatioissa:

a <- 20

b <- 5

Yhteenlasku

sum <- a + b # 25

Kertolasku

product <- a * b # 100

Jakolasku

division <- a / b # 4

Erikoismuuttujat

R sisältää kolme erikoisarvoa:

1. **NA**: Tarkoittaa "ei saatavilla" (missing value).
2. value <- NA
3. is.na(value) # Tarkistaa, onko arvo NA
4. **NULL**: Tarkoittaa "tyhjää arvoa" (null value).
5. empty <- NULL
6. **Inf ja -Inf**: Käytetään äärettömyyden ilmaisemiseen.
7. infinity <- 1 / 0 # Inf
8. **NaN**: Tarkoittaa "ei numero" (not a number).
9. not_number <- 0 / 0 # NaN

Muuttujien hallinta

Näytä kaikki nykyiset muuttujat

ls() # Tulostaa kaikki ympäristössä olevat muuttujat

Poista muuttuja

rm(x) # Poistaa muuttujan x

Käytännön esimerkki

Myynnin seuranta

products_sold <- 120 # Kuinka monta tuotetta myytiin

price_per_unit <- 25 # Tuotteen hinta

Laske kokonaistulot

total_revenue <- products_sold * price_per_unit

print(total_revenue) # Tulostaa: 3000

R-kielen loogiset operaatiot (Logical Operators)

Mikä on looginen operaatio?

Loogiset operaatiot vertaavat arvoja ja palauttavat **TRUE** tai **FALSE**. Niitä käytetään yleisesti ehtolauseissa, tietojen suodattamisessa ja päätöksenteossa ohjelmoinnin aikana.

Loogiset operaattorit

R-kielessä loogisia operaattoreita ovat:

Operaattori	Tarkoitus	Esimerkki	Tulos
==	Onko yhtä suuri?	5 == 5	TRUE
!=	Onko erisuuri?	5 != 3	TRUE
<	Onko pienempi?	3 < 5	TRUE
>	Onko suurempi?	5 > 3	TRUE
<=	Onko pienempi tai yhtä suuri?	3 <= 3	TRUE
>=	Onko suurempi tai yhtä suuri?	5 >= 3	TRUE
&	Ja (AND)	(5 > 3) & (2 < 4)	TRUE
`	`	Tai (OR)	`(5 > 3)
!	Ei (NOT)	!(5 > 3)	FALSE

Perusesimerkkejä loogisista operaattoreista

1. Yhden ehdon tarkistus

x <- 10

x == 10 # Tarkistaa, onko x yhtä suuri kuin 10 (TRUE)

x > 5 # Tarkistaa, onko x suurempi kuin 5 (TRUE)

x < 3 # Tarkistaa, onko x pienempi kuin 3 (FALSE)

2. Usean ehdon yhdistäminen

x <- 10

y <- 20

```
(x > 5) & (y < 30)  # Molemmat ehdot totta (TRUE)
(x < 5) | (y > 15)  # Ainakin yksi ehto totta (TRUE)
!(x == 10)        # Käänteinen arvo (FALSE)
```

Loogiset operaatiot vektoreissa

Loogiset operaatiot voidaan soveltaa myös vektoreihin, ja tulos on vektori, jossa on loogisia arvoja (**TRUE** tai **FALSE**).

Esimerkki:

```
# Vektorien luonti
a <- c(10, 20, 30)
b <- c(15, 20, 25)

# Yhtäsuuruus
a == b  # FALSE  TRUE  FALSE

# Suuruusvertailu
a > 15  # FALSE  TRUE  TRUE

# Looginen JA (AND)
(a > 15) & (b < 30)  # FALSE  TRUE  TRUE

# Looginen TAI (OR)
(a > 15) | (b < 30)  # TRUE  TRUE  TRUE
```

Kaavojen lyhennetyt muodot

R tarjoaa myös lyhennettyjä loogisia operaattoreita erityisesti, kun ehtoja tarkastellaan **kokonaisessa vektorissa**:

Operaattori	Tarkoitus	Esimerkki	Tulos
&&	Lyhennetty AND	(5 > 3) && (2 < 4)	TRUE
||	Lyhennetty OR		

Erona on, että && ja || tarkistavat vain ensimmäiset elementit, kun taas & ja | käsittelevät koko vektorin.

Esimerkki:

```
# AND ja OR ensimmäiselle elementille
a <- c(TRUE, FALSE, TRUE)
b <- c(FALSE, TRUE, TRUE)

a && b  # Tarkastaa vain ensimmäisen elementin (FALSE)
a || b  # Tarkastaa vain ensimmäisen elementin (TRUE)
```

Loogisten ehtojen hyödyntäminen

1. Ehtolauseet (if, else if, else)

Loogisia operaattoreita käytetään ehtolauseiden kanssa:

```
x <- 10

if (x > 5) {
  print("x on suurempi kuin 5")
} else if (x == 5) {
  print("x on yhtä suuri kuin 5")
} else {
  print("x on pienempi kuin 5")
}
```

2. Tietojen suodattaminen

Voit käyttää loogisia ehtoja tietojen suodattamiseen vektoreista tai data.frameistä:

```
# Vektorin suodatus
numbers <- c(1, 2, 3, 4, 5, 6)
numbers[numbers > 3]  # Palauttaa arvot: 4, 5, 6

# data.frame-suodatus
df <- data.frame(Name = c("A", "B", "C"), Age = c(20, 25, 30))
subset(df, Age > 20)  # Palauttaa rivit, joissa ikä > 20
```

Erikoistapaukset: NA ja NaN

Loogisissa vertailuissa **NA** (puuttuva arvo) voi tuottaa erityisiä tuloksia:

Esimerkki:

```
x <- NA
x == 10  # Palauttaa: NA

is.na(x)  # Tarkistaa, onko x puuttuva arvo (TRUE)
```

Käytännön esimerkki

```
# Oletetaan lista arvosanoista
grades <- c(85, 92, 78, 90, 66, 58, 89)

# Tarkistetaan, ketkä saivat arvosanan yli 80
high_grades <- grades[grades > 80]
print(high_grades)  # Tulostaa: 85, 92, 90, 89

# Ketkä saivat hylätyn (alle 60)?
failed <- grades[grades < 60]
print(failed)  # Tulostaa: 58
```

Print()-funktio R-kielessä

Mikä on print()?

R-kielen **print()**-funktio on yksinkertainen ja tehokas tapa tulostaa tietoa konsoliin. Se on yksi yleisimmin käytetyistä funktioista ohjelmoinnissa, koska se auttaa tarkistamaan muuttujien arvot, debuggaamaan koodia ja näyttämään tuloksia.

---

print()-funktion käyttö

print()-funktio ottaa yhden argumentin (tulostettavan objektin) ja näyttää sen arvon konsolissa. Se toimii kaikenlaisten objektien kanssa, kuten:

- Numerot
- Merkkijonot
- Vektorit
- Matriisit
- Data.frame-rakenteet

Esimerkki:

```
# Yksinkertaisia tulosteita
print(42)        # Tulostaa: [1] 42
print("Hello, R!") # Tulostaa: [1] "Hello, R!"

# Muuttujan tulostus
x <- 100
print(x)         # Tulostaa: [1] 100
```

Tulostuksen oletusmuoto

Tulosteessa näkyvä **[1]** kertoo, että ensimmäinen arvo sijaitsee ensimmäisessä indeksissä (indeksointi alkaa aina yhdestä).

Esimerkki:

```
x <- c(10, 20, 30)
print(x)
# Tulostaa:
# [1] 10 20 30
```

Tulostaminen ilman print()-funktiota

R tulostaa muuttujan arvon automaattisesti, jos kirjoitat vain muuttujan nimen:

```
x <- 50
x  # Tulostaa: [1] 50
```

Mutta **print()** on hyödyllinen erityisesti funktioiden sisällä, koska funktiot eivät oletuksena tulosta arvoja ilman erillistä käskyä.

print()-funktion käyttö funktioiden sisällä

Kun kirjoitat omia funktioita, voit käyttää **print()**-funktiota näyttääksesi välituloksia debuggausta tai tarkastelua varten.

Esimerkki:

```
my_function <- function(x) {
  print(paste("Annettu arvo on:", x))
  return(x * 2)
}

my_function(10)
# Tulostaa:
# [1] "Annettu arvo on: 10"
# Palauttaa: 20
```

Monimutkaisten rakenteiden tulostaminen

print() toimii myös monimutkaisempien objektien, kuten data.frame- tai listarakenteiden kanssa.

Esimerkkejä:

```
# Data.frame-tulostus
df <- data.frame(
  Name = c("Alice", "Bob", "Charlie"),
  Age = c(25, 30, 35)
)
print(df)
# Tulostaa:
#      Name Age
# 1   Alice  25
# 2     Bob  30
# 3 Charlie  35

# Listan tulostus
my_list <- list(a = 1:5, b = "Hello", c = TRUE)
print(my_list)
# Tulostaa:
# $a
# [1] 1 2 3 4 5
#
# $b
# [1] "Hello"
#
# $c
# [1] TRUE
```

Tulostuksen muotoiluvinkkejä

print()-funktio näyttää arvot sellaisenaan, mutta joskus tulostus halutaan muotoilla paremmin. Käytä esimerkiksi **paste()**- tai **sprintf()**-funktiota yhdessä print()-funktion kanssa.

Esimerkkejä:

```
# Käytä paste() yhdistämään tekstiä ja muuttujia
x <- 42
print(paste("Luvun arvo on:", x))
# Tulostaa: [1] "Luvun arvo on: 42"

# Käytä sprintf() tarkempaan muotoiluun
y <- 3.14159
print(sprintf("Pi-arvo on noin %.2f", y))
```

Tulostaa: [1] "Pi-arvo on noin 3.14"

Eroja print() ja muiden tulostusfunktioiden välillä

Vaikka **print()** on yleisin tapa tulostaa, R tarjoaa myös muita funktioita erityisiin käyttötapauksiin:

1. **cat()**
    - Yhdistää ja tulostaa tekstiä ilman [1]-merkintää.
    - Sopii yksinkertaisiin tekstitulosteisiin.
2. cat("Hello,", "world!", "\n")
3. # Tulostaa: Hello, world!
4. **message()**
    - Tulostaa viestejä, joita voidaan käyttää debuggaamiseen.
5. message("Tämä on viesti!")
6. # Tulostaa: Tämä on viesti!
7. **str()**
    - Näyttää objektin rakenteen tiivistetyssä muodossa.
8. str(df)
9. # Tulostaa:
10. # 'data.frame': 3 obs. of 2 variables:
11. # $ Name: chr "Alice" "Bob" "Charlie"
12. # $ Age : num 25 30 35

Käytännön esimerkki

Esimerkki pseudodatan tulostamisesta:

```
# Luo pseudodata
df <- data.frame(
  Product = c("A", "B", "C"),
  Sales = c(100, 200, 150)
)

# Tulosta koko taulukko
print(df)

# Tulosta vain yksittäinen sarake
print(df$Sales)

# Yhdistä teksti ja data
print(paste("Ensimmäisen tuotteen myynti:", df$Sales[1]))
```

Vektorit (Vectors) R-kielessä

Mikä on vektori?

Vektori on R:n perusdatatyyppi, joka on **samantyyppisten arvojen järjestetty kokoelma**. Vektorit voivat sisältää esimerkiksi numeroita, merkkijonoja tai loogisia arvoja, mutta eivät voi yhdistää eri tyyppisiä arvoja.

Vektorin luominen

Vektori luodaan **c()**-funktiolla (combine).

Esimerkkejä:

```
# Numerovektori
numbers <- c(10, 20, 30, 40)

# Merkkijonovektori
names <- c("Alice", "Bob", "Charlie")

# Looginen vektori
logical_values <- c(TRUE, FALSE, TRUE)
```

Tulosta vektorin sisältö:

```
print(numbers)  # Tulostaa: [1] 10 20 30 40
```

Vektorin tietotyypit

R tukee useita tietotyyppejä vektoreissa:

Tietotyyppi	Kuvaus	Esimerkki
numeric	Desimaaliluvut ja kokonaisluvut	c(1, 2.5, 3.14)
character	Teksti	c("apple", "banana")
logical	Loogiset arvot	c(TRUE, FALSE, TRUE)
integer	Kokonaisluvut	c(1L, 2L, 3L) (lisää L)

Sekatyyppiset arvot muunnetaan automaattisesti:

```
mixed <- c(1, "two", TRUE)
print(mixed)  # Tulostaa: [1] "1" "two" "TRUE" (kaikki merkkijonoina)
```

Vektorin käsittely

1. Indeksointi

Vektorin tiettyyn elementtiin pääsee käsiksi hakasulkeilla **[]**.

```
# Esimerkkivektori
numbers <- c(10, 20, 30, 40)

# Pääsy tiettyihin elementteihin
numbers[1]   # Ensimmäinen arvo: 10
numbers[2:3]  # Toinen ja kolmas arvo: 20, 30
numbers[c(1, 4)]  # Ensimmäinen ja neljäs arvo: 10, 40
```

2. Muokkaaminen

Voit päivittää vektorin elementtejä samalla tavalla.

```
numbers[2] <- 25  # Päivittää toisen arvon 25:ksi
print(numbers)    # Tulostaa: [1] 10 25 30 40
```

3. Ehdollinen valinta

Voit valita elementtejä ehdon perusteella.

```
numbers <- c(10, 20, 30, 40)

# Valitse luvut, jotka ovat suurempia kuin 20
filtered <- numbers[numbers > 20]
print(filtered)  # Tulostaa: [1] 30 40
```

Operaatiot vektoreilla

R tukee monenlaisia laskutoimituksia vektoreilla.

1. Aritmeettiset operaatiot

Operaatiot suoritetaan elementtikohtaisesti:

```
a <- c(1, 2, 3)
b <- c(4, 5, 6)

sum <- a + b   # [1] 5 7 9
```

```
diff <- a - b   # [1] -3 -3 -3
prod <- a * b   # [1] 4 10 18
div <- b / a    # [1] 4.0 2.5 2.0
```

2. Loogiset operaatiot

Vektorin arvoja voidaan vertailla loogisilla operaattoreilla:

```
x <- c(10, 20, 30)

x > 15      # [1] FALSE  TRUE  TRUE
x == 20     # [1] FALSE  TRUE  FALSE
x != 10     # [1] FALSE  TRUE  TRUE
```

3. Aggregaattifunktiot

```
x <- c(5, 10, 15, 20)

sum(x)      # Summa: 50
mean(x)     # Keskiarvo: 12.5
min(x)      # Pienin arvo: 5
max(x)      # Suurin arvo: 20
length(x)   # Alkioiden lukumäärä: 4
```

Erityistoiminnot vektoreilla

1. Vektorin luonti sarjoilla

Sarjojen avulla voit luoda vektoreita helposti:

```
# Sarjat
x <- 1:10       # [1] 1 2 3 4 5 6 7 8 9 10
y <- seq(1, 10, by = 2)  # [1] 1 3 5 7 9
z <- rep(5, times = 4)   # [1] 5 5 5 5
```

2. Vektorin lajittelu

```
x <- c(30, 10, 50, 20)

# Nouseva järjestys
sorted <- sort(x)  # [1] 10 20 30 50

# Laskeva järjestys
desc_sorted <- sort(x, decreasing = TRUE)  # [1] 50 30 20 10
```

3. Vektorin yhdistäminen

```
a <- c(1, 2, 3)
b <- c(4, 5, 6)

combined <- c(a, b)  # [1] 1 2 3 4 5 6
```

Vektorin yhteensopivuus

R pyrkii automaattisesti sovittamaan eri pituiset vektorit yhteen laskutoimituksissa:

```
a <- c(1, 2, 3)
b <- c(10, 20)

# Lyhyempi vektori toistetaan automaattisesti
result <- a + b  # [1] 11 22 13 (b toistettiin: [10 20 10])
```

Käytännön esimerkkejä

Esimerkki 1: Lämpötilojen analyysi

```
temps <- c(20, 22, 19, 25, 30)

# Laske keskiarvo
average_temp <- mean(temps)
print(average_temp)  # Tulostaa: 23.2

# Valitse lämpötilat, jotka ovat yli 22
hot_days <- temps[temps > 22]
print(hot_days)  # Tulostaa: [1] 25 30
```

Esimerkki 2: Myyntidatan käsittely

```
sales <- c(100, 200, 150, 250)
```

```
# Yhteensä myyntiä
total_sales <- sum(sales)
print(total_sales)  # Tulostaa: 700

# Tuotteet, joiden myynti oli yli 150
high_sales <- sales[sales > 150]
print(high_sales)  # Tulostaa: [1] 200 250
```

Listat (Lists) R-kielessä

Mikä on lista?

Lista on R-kielessä monipuolinen tietorakenne, joka voi sisältää **erityyppisiä ja erikokoisia arvoja**. Toisin kuin vektorit, joissa kaikki arvot ovat saman tyyppisiä, lista voi yhdistää numeroita, merkkijonoja, loogisia arvoja, vektoreita, data.frame-objekteja tai muita listoja.

Listan luominen

Lista luodaan **list()**-funktiolla.

Esimerkki:

```
# Yksinkertainen lista
my_list <- list(10, "text", TRUE)
print(my_list)
# Tulostaa:
# [[1]]
# [1] 10
#
# [[2]]
# [1] "text"
#
# [[3]]
# [1] TRUE
```

Nimetyt listan elementit

Listaelementtejä voidaan nimetä, jotta niihin on helpompi viitata.

Esimerkki:

```
# Nimetty lista
person <- list(
 name = "Alice",
 age = 30,
 is_employed = TRUE
```

)

print(person)

Tulostaa:

$name

[1] "Alice"

#

$age

[1] 30

#

$is_employed

[1] TRUE

Listan elementtien hakeminen

1. **Hakeminen indekseillä**
   Käytä hakasulkeita **[[ ]]** tai **[ ]** hakemiseen.
2. my_list <- list(10, "text", TRUE)
3.
4. my_list[[1]] # Hakee ensimmäisen elementin (10)
5. my_list[[2]] # Hakee toisen elementin ("text")
6. **Hakeminen nimillä**
   Jos listaelementeillä on nimet, niitä voidaan hakea $-operaattorilla.
7. person$name   # Hakee arvon "Alice"
8. person$is_employed # Hakee arvon TRUE
9. **Hakeminen useista elementeistä**
   Useamman elementin hakemiseen käytetään yksinkertaisia hakasulkeita [ ], jolloin tulos on alilista.
10. sublist <- my_list[1:2]
11. print(sublist) # Tulostaa alilistan, joka sisältää ensimmäisen ja toisen elementin

---

Listan elementtien muokkaaminen

1. **Muokkaa olemassa olevaa elementtiä**:
2. person$age <- 35 # Päivittää iän arvoksi 35
3. person[[1]] <- "Bob" # Päivittää nimen arvoksi "Bob"
4. **Lisää uusi elementti**:
5. person$city <- "Helsinki" # Lisää uuden elementin 'city'
6. **Poista elementti**:
7. person$age <- NULL # Poistaa 'age'-elementin

Listan yhdistäminen

Listoja voidaan yhdistää **c()**-funktiolla.

list1 <- list(1, 2, 3)

list2 <- list("a", "b", "c")

combined <- c(list1, list2)

print(combined)

Tulostaa:

[[1]]

[1] 1

#

[[2]]

[1] 2

#

[[3]]

[1] 3

#

[[4]]

[1] "a"

#

[[5]]

[1] "b"

#

[[6]]

[1] "c"

Listan sisäkkäisyys

Listan elementit voivat itsessään olla listoja, jolloin saadaan hierarkkinen rakenne.

Esimerkki:

```
nested_list <- list(
 numbers = list(1, 2, 3),
 texts = list("a", "b", "c")
)
print(nested_list)
# Tulostaa:
# $numbers
# $numbers[[1]]
# [1] 1
#
# $numbers[[2]]
# [1] 2
#
# $numbers[[3]]
# [1] 3
#
# $texts
# $texts[[1]]
# [1] "a"
#
# $texts[[2]]
# [1] "b"
#
# $texts[[3]]
# [1] "c"
```

Hakeminen sisäkkäisestä listasta:

```
nested_list$numbers[[2]]  # Hakee arvon 2
nested_list$texts[[3]]   # Hakee arvon "c"
```

Listan muunnokset

1. **Muuta lista vektoriksi**:
2. my_list <- list(1, 2, 3)
3. vector <- unlist(my_list)
4. print(vector) # Tulostaa: [1] 1 2 3
5. **Muuta lista data.frame-muotoon**:
6. my_list <- list(name = c("Alice", "Bob"), age = c(30, 25))
7. df <- as.data.frame(my_list)
8. print(df)
9. # Tulostaa:
10. #   name age
11. # 1 Alice 30
12. # 2   Bob 25

Listan tutkiminen

1. **Näytä listan rakenne**:
2. str(person)
3. # Tulostaa:
4. # List of 3
5. # $ name   : chr "Alice"
6. # $ age   : num 30
7. # $ is_employed: logi TRUE
8. **Listan pituus**:
9. length(my_list) # Palauttaa elementtien lukumäärän

Käytännön esimerkkejä

Esimerkki 1: Opiskelijadata listassa

```
student <- list(
 name = "Anna",
```

```
  grades = c(90, 85, 92),
  passed = TRUE
)

# Tulosta nimi
print(student$name)

# Laske keskiarvo arvosanoista
average_grade <- mean(student$grades)
print(average_grade)  # Tulostaa: 89
```

Esimerkki 2: Sisäkkäiset listat

```
# Tuoteryhmien lista
products <- list(
  electronics = list("phone", "laptop"),
  groceries = list("bread", "milk", "cheese")
)

# Tulosta kaikki elektroniikkatuotteet
print(products$electronics)

# Lisää uusi tuote
products$electronics <- c(products$electronics, "tablet")
print(products$electronics)
```

Matriisit (Matrices) R-kielessä

Mikä on matriisi?

Matriisi on R-kielessä kaksiulotteinen tietorakenne, jossa **kaikki arvot ovat saman tyyppisiä** (esim. numerot, merkkijonot tai loogiset arvot). Se voidaan ajatella taulukkona, jossa on rivejä ja sarakkeita.

Matriisin luominen

Matriisi luodaan **matrix()**-funktiolla.

Perusmuoto

matrix(data, nrow, ncol, byrow = FALSE)

- **data**: Arvot, jotka täyttävät matriisin.
- **nrow**: Rivien määrä.
- **ncol**: Sarakkeiden määrä.
- **byrow**: Jos **TRUE**, arvot täytetään rivi kerrallaan; muuten sarake kerrallaan.

Esimerkkejä

1. Matriisi numeerisilla arvoilla

```
# Matriisi, jossa arvot täytetään sarake kerrallaan
m <- matrix(1:6, nrow = 2, ncol = 3)
print(m)
# Tulostaa:
#      [,1] [,2] [,3]
# [1,]    1    3    5
# [2,]    2    4    6
```

2. Matriisi rivien mukaan täytettynä

```
m_by_row <- matrix(1:6, nrow = 2, ncol = 3, byrow = TRUE)
print(m_by_row)
# Tulostaa:
#      [,1] [,2] [,3]
# [1,]    1    2    3
# [2,]    4    5    6
```

3. Merkkijonomatriisi

```
m_text <- matrix(c("a", "b", "c", "d"), nrow = 2, ncol = 2)

print(m_text)

# Tulostaa:

#     [,1] [,2]

# [1,] "a"  "c"

# [2,] "b"  "d"
```

Matriisin ominaisuudet

Voit tutkia matriisin rakennetta ja ominaisuuksia seuraavasti:

- **Rivien määrä**: nrow(m)
- **Sarakkeiden määrä**: ncol(m)
- **Matriisin koko (elementtien määrä)**: length(m)
- **Dimensiot (rivien ja sarakkeiden määrä)**: dim(m)

Esimerkki

```
nrow(m)  # 2

ncol(m)  # 3

dim(m)   # c(2, 3)

length(m)  # 6
```

Matriisin elementtien käsittely

1. Hakeminen

Voit käyttää hakasulkeita [row, column] päästäksesi yksittäisiin elementteihin, riveihin tai sarakkeisiin.

```
# Elementti riviltä 1, sarakkeesta 2

m[1, 2]  # 3


# Kokonainen rivi

m[1, ]  # c(1, 3, 5)


# Kokonainen sarake

m[, 2]  # c(3, 4)
```

2. Elementtien muokkaaminen

```
# Päivitä arvo rivillä 2, sarakkeessa 3

m[2, 3] <- 10

print(m)

# Tulostaa:

#     [,1] [,2] [,3]

# [1,]   1   3   5

# [2,]   2   4  10
```

Matriisioperaatiot

R tukee monenlaisia matriiseihin liittyviä operaatioita, kuten aritmeettisia laskutoimituksia, transponointia ja matriisikertolaskuja.

1. Perusaritmetiikka

Aritmeettiset operaatiot toimivat elementtikohtaisesti:

```
# Matriisin luonti

m <- matrix(1:6, nrow = 2, ncol = 3)


# Yhteenlasku

m + 2

#     [,1] [,2] [,3]

# [1,]   3   5   7

# [2,]   4   6   8


# Kertolasku

m * 2

#     [,1] [,2] [,3]

# [1,]   2   6  10

# [2,]   4   8  12
```

2. Matriisikertolasku

Käytä **%*%**-operaattoria matriisikertolaskuun.

```
m1 <- matrix(1:4, nrow = 2)
m2 <- matrix(5:8, nrow = 2)

result <- m1 %*% t(m2)  # Huom! Käytetään transponointia
print(result)
# Tulostaa:
#      [,1] [,2]
# [1,]   23   53
# [2,]   31   71
```

3. Transponointi

Matriisin kääntäminen (rivien ja sarakkeiden vaihto):

```
t(m)
# Tulostaa:
#      [,1] [,2]
# [1,]    1    2
# [2,]    3    4
# [3,]    5    6
```

4. Rivien ja sarakkeiden summa tai keskiarvo

```
rowSums(m)    # Rivien summat
colSums(m)    # Sarakkeiden summat
rowMeans(m)   # Rivien keskiarvot
colMeans(m)   # Sarakkeiden keskiarvot
```

Matriisin yhdistäminen

1. Rivien lisääminen

```
m <- matrix(1:6, nrow = 2)
new_row <- c(7, 8, 9)

m_combined <- rbind(m, new_row)
print(m_combined)
# Tulostaa:
#      [,1] [,2] [,3]
# [1,]    1    3    5
# [2,]    2    4    6
# [3,]    7    8    9
```

2. Sarakkeiden lisääminen

```
new_col <- c(10, 11)
m_combined <- cbind(m, new_col)
print(m_combined)
# Tulostaa:
#      [,1] [,2] [,3] [,4]
# [1,]    1    3    5   10
# [2,]    2    4    6   11
```

Käytännön esimerkkejä

Esimerkki 1: Taulukon analyysi

```
# Myyntidataa riveittäin: tuotteet, sarakkeina kuukaudet
sales <- matrix(c(100, 200, 150, 300, 400, 350), nrow = 2, byrow = TRUE)
rownames(sales) <- c("Product_A", "Product_B")
colnames(sales) <- c("Jan", "Feb", "Mar")

print(sales)
# Tulostaa:
#           Jan Feb Mar
# Product_A  100 200 150
# Product_B  300 400 350

# Kuukausien summat
print(colSums(sales))  # Jan: 400, Feb: 600, Mar: 500
```

Esimerkki 2: Opiskelijoiden arvosanat

```
grades <- matrix(c(85, 90, 78, 88, 92, 80), nrow = 2)
rownames(grades) <- c("Student_1", "Student_2")
```

```
colnames(grades) <- c("Math", "Science", "History")

print(grades)
# Tulostaa:
#         Math Science History
# Student_1   85     88     92
# Student_2   90     78     80

# Keskiarvo opiskelijaa kohden
student_means <- rowMeans(grades)
print(student_means)
# Tulostaa:
# Student_1 Student_2
#      88      82.7
```

Kuvaajat (Data Frames) R-kielessä

Mikä on dataframe?

Dataframe on R:n yleisin tietorakenne, jota käytetään taulukkomuotoisen datan käsittelyyn. Se muistuttaa Excel-taulukkoa, jossa:

- **Rivit** vastaavat havaintoja.
- **Sarakkeet** vastaavat muuttujia.
- Jokainen sarake voi sisältää erilaista tietotyyppiä (numeroita, merkkijonoja, loogisia arvoja jne.).

Dataframen luominen

1. Manuaalisesti

Voit luoda dataframen **data.frame()**-funktiolla.

```
df <- data.frame(
  Name = c("Alice", "Bob", "Charlie"),
  Age = c(25, 30, 35),
  Employed = c(TRUE, TRUE, FALSE)
)
print(df)
# Tulostaa:
#      Name Age Employed
# 1   Alice  25    TRUE
# 2     Bob  30    TRUE
# 3 Charlie  35   FALSE
```

---

2. CSV-tiedostosta

Voit ladata dataframen ulkoisesta tiedostosta, kuten CSV-tiedostosta.

```
df <- read.csv("data.csv")
print(head(df))  # Tulostaa ensimmäiset 6 riviä
```

---

3. Dataframen rakenne

Voit tarkastella dataframen rakennetta seuraavilla komennoilla:

```
str(df)      # Näyttää datan rakenteen
summary(df)  # Näyttää yhteenvetotilastot
dim(df)      # Palauttaa rivien ja sarakkeiden määrän
nrow(df)     # Rivien määrä
ncol(df)     # Sarakkeiden määrä
colnames(df) # Sarakkeiden nimet
rownames(df) # Rivien nimet
```

Dataframen käsittely

1. Pääsy yksittäisiin elementteihin

Käytä hakasulkeita **[row, column]** tai $-operaattoria.

```
# Pääsy yksittäiseen elementtiin
df[1, 2]  # Ensimmäisen rivin toinen sarake: 25

# Pääsy kokonaiseen sarakkeeseen
df$Name   # Sarake "Name": c("Alice", "Bob", "Charlie")

# Pääsy kokonaiseen riviin
df[2, ]  # Toinen rivi
```

---

2. Suodattaminen ehdon perusteella

Voit suodattaa rivejä ehtojen avulla.

```
# Suodata henkilöt, joiden ikä on yli 30
subset_df <- subset(df, Age > 30)
print(subset_df)
# Tulostaa:
#     Name Age Employed
# 3 Charlie  35    FALSE
```

---

3. Rivien ja sarakkeiden lisääminen

Uuden sarakkeen lisääminen:

```
df$Salary <- c(50000, 60000, 45000)
print(df)
# Tulostaa:
#     Name Age Employed Salary
# 1   Alice  25    TRUE  50000
# 2     Bob  30    TRUE  60000
# 3 Charlie  35   FALSE  45000
```

Uuden rivin lisääminen:

```
new_row <- data.frame(Name = "David", Age = 40, Employed = TRUE, Salary = 70000)
df <- rbind(df, new_row)
print(df)
# Tulostaa:
#     Name Age Employed Salary
# 1   Alice  25    TRUE  50000
# 2     Bob  30    TRUE  60000
# 3 Charlie  35   FALSE  45000
# 4   David  40    TRUE  70000
```

---

4. Rivien ja sarakkeiden poistaminen

```
# Poista sarake
df$Salary <- NULL

# Poista rivi
df <- df[-2, ]  # Poistaa toisen rivin
```

Dataframen muokkaaminen

1. Sarakkeiden uudelleennimeäminen

```
colnames(df) <- c("FullName", "AgeYears", "IsEmployed")
print(df)
# Tulostaa:
#    FullName AgeYears IsEmployed
```

```
# 1   Alice     25     TRUE
# 2     Bob     30     TRUE
# 3 Charlie     35     FALSE
```

2. Data-arvojen muokkaaminen

```
df$AgeYears <- df$AgeYears + 1  # Lisää yhden jokaisen ikään
```

Data-analyysi dataframeilla

1. Ryhmitys ja yhteenvedot

Voit käyttää **aggregate()**-funktiota ryhmäkohtaisiin laskelmiin.

```
# Esimerkki: Laske keski-ikä työllisyyden perusteella
aggregate(Age ~ Employed, data = df, FUN = mean)
# Tulostaa:
#   Employed Age
# 1    FALSE  35
# 2     TRUE  27.5
```

2. Ryhmittely ja summat dplyr-kirjastolla

Käytä **dplyr**-pakettia tehokkaampaan data-analyysiin.

```
library(dplyr)

df %>%
  group_by(Employed) %>%
  summarise(
    AvgAge = mean(Age),
    Count = n()
  )
# Tulostaa:
# # A tibble: 2 × 3
#   Employed AvgAge Count
#   <lgl>    <dbl> <int>
# 1 FALSE      35    1
# 2 TRUE       27.5  2
```

Tietojen tallentaminen

1. Tallentaminen CSV-tiedostoksi

```
write.csv(df, "output.csv", row.names = FALSE)
```

2. Lataaminen R:n omaan tiedostomuotoon

```
save(df, file = "data.RData")
load("data.RData")  # Lataa takaisin
```

Käytännön esimerkkejä

Esimerkki 1: Opiskelijoiden arvosanat

```
students <- data.frame(
  Name = c("Alice", "Bob", "Charlie"),
  Math = c(90, 85, 88),
  Science = c(92, 80, 85),
  History = c(88, 87, 90)
)

# Laske keskiarvo jokaiselle opiskelijalle
students$Average <- rowMeans(students[, c("Math", "Science", "History")])
print(students)
# Tulostaa:
#     Name Math Science History Average
# 1   Alice   90     92     88  90.00
# 2     Bob   85     80     87  84.00
# 3 Charlie   88     85     90  87.67
```

Esimerkki 2: Myyntidatan analyysi

```
sales <- data.frame(
  Product = c("A", "B", "C", "A", "B", "C"),
  Month = c("Jan", "Jan", "Jan", "Feb", "Feb", "Feb"),
  Revenue = c(100, 200, 150, 120, 220, 180)
)

# Laske kuukausittaiset kokonaistulot
```

```
monthly_sales <- aggregate(Revenue ~ Month, data = sales, sum)
print(monthly_sales)
# Tulostaa:
#   Month Revenue
# 1   Feb     520
# 2   Jan     450
```

Ohjausrakenteet (Flow Control) R-kielessä

Mikä on ohjausrakenne?

Ohjausrakenteet määrittelevät ohjelman suoritusjärjestyksen ja päätöksenteon. R-kielessä yleisimpiä ohjausrakenteita ovat:

1. **Ehtolauseet**: if, else if, else
2. **Toistorakenteet**: for, while, repeat
3. **Päätöksenteon lyhennetyt muodot**: ifelse()

---

1. Ehtolauseet: if, else if, else

Ehtolauseiden avulla ohjelma suorittaa erilaisia toimintoja riippuen tietyistä ehdoista.

Yksinkertainen if-lause

```
x <- 10

if (x > 5) {
  print("x on suurempi kuin 5")
}
# Tulostaa: "x on suurempi kuin 5"
```

if ja else

```
x <- 3

if (x > 5) {
  print("x on suurempi kuin 5")
} else {
  print("x on pienempi tai yhtä suuri kuin 5")
}
# Tulostaa: "x on pienempi tai yhtä suuri kuin 5"
```

Useita ehtoja: if, else if, else

```
x <- 7

if (x > 10) {
  print("x on suurempi kuin 10")
```

```
} else if (x > 5) {
  print("x on suurempi kuin 5 mutta pienempi tai yhtä suuri kuin 10")
} else {
  print("x on 5 tai pienempi")
}
# Tulostaa: "x on suurempi kuin 5 mutta pienempi tai yhtä suuri kuin 10"
```

---

2. Lyhennetty ehtolause: ifelse()

ifelse()-funktiolla voit käyttää ehtolauseita vektorien kanssa.

Esimerkki:

```
numbers <- c(10, 3, 8, 6)

result <- ifelse(numbers > 5, "Suuri", "Pieni")
print(result)
# Tulostaa: [1] "Suuri" "Pieni" "Suuri" "Suuri"
```

---

3. Toistorakenteet

R tarjoaa kolme pääasiallista toistorakennetta: for, while, ja repeat.

3.1 for-silmukka

for-silmukka toistaa toiminnon tietyn kokoelman läpi.

Yksinkertainen for-silmukka

```
# Tulosta luvut 1–5
for (i in 1:5) {
  print(i)
}
# Tulostaa: 1, 2, 3, 4, 5
```

for-silmukka vektoreiden kanssa

```
fruits <- c("apple", "banana", "cherry")

for (fruit in fruits) {
  print(paste("I like", fruit))
}
# Tulostaa:
# "I like apple"
# "I like banana"
# "I like cherry"
```

3.2 while-silmukka

while-silmukka toistaa toiminnon niin kauan kuin ehto on **TRUE**.

Esimerkki:

```
x <- 1

while (x <= 5) {
  print(x)
  x <- x + 1
}
# Tulostaa: 1, 2, 3, 4, 5
```

3.3 repeat-silmukka

repeat-silmukka jatkuu loputtomasti, kunnes se keskeytetään **break**-komennolla.

Esimerkki:

```
x <- 1

repeat {
  print(x)
  x <- x + 1
  if (x > 5) {
    break
  }
}
# Tulostaa: 1, 2, 3, 4, 5
```

---

4. Keskeytys ja jatkaminen: break ja next

- **break**: Keskeyttää toiston.
- **next**: Ohittaa nykyisen iteraation ja siirtyy seuraavaan.

Esimerkki break-komennosta:

```
for (i in 1:10) {
 if (i == 5) {
  break
 }
 print(i)
}
# Tulostaa: 1, 2, 3, 4
```

Esimerkki next-komennosta:

```
for (i in 1:5) {
 if (i == 3) {
  next
 }
 print(i)
}
# Tulostaa: 1, 2, 4, 5 (ohittaa 3:n)
```

---

5. Pesäkkäiset silmukat

Toistorakenteita voidaan yhdistää toisiinsa.

```
for (i in 1:3) {
 for (j in 1:2) {
  print(paste("i =", i, ", j =", j))
 }
}
# Tulostaa:
# "i = 1 , j = 1"
# "i = 1 , j = 2"
# "i = 2 , j = 1"
# "i = 2 , j = 2"
# "i = 3 , j = 1"
# "i = 3 , j = 2"
```

Käytännön esimerkkejä

Esimerkki 1: Numeroiden luokittelu

```
numbers <- c(5, 10, 15, 20)

for (num in numbers) {
 if (num < 10) {
  print(paste(num, "on pieni luku"))
 } else {
  print(paste(num, "on suuri luku"))
 }
}
# Tulostaa:
# "5 on pieni luku"
# "10 on suuri luku"
# "15 on suuri luku"
# "20 on suuri luku"
```

Esimerkki 2: Summa laskettuna while-silmukalla

```
sum <- 0
i <- 1

while (i <= 5) {
 sum <- sum + i
 i <- i + 1
}
print(sum)  # Tulostaa: 15
```

Esimerkki 3: Ehtojen soveltaminen data.frameen

```
df <- data.frame(
 Name = c("Alice", "Bob", "Charlie"),
```

```
  Score = c(85, 50, 75)
)

df$Grade <- ifelse(df$Score >= 80, "Excellent",
                   ifelse(df$Score >= 60, "Good", "Fail"))
print(df)
# Tulostaa:
#     Name Score    Grade
# 1   Alice    85 Excellent
# 2     Bob    50     Fail
# 3 Charlie    75     Good
```

Funktiot R-kielessä

Mikä on funktio?

Funktio on R-kielessä koodin uudelleenkäytettävä yksikkö, joka suorittaa tietyn tehtävän. Funktiot tekevät koodista järjestelmällisempää ja helpottavat monimutkaisten laskelmien hallintaa.

Funktioiden rakenne

Funktion perusrakenne R:ssä:

```
my_function <- function(arg1, arg2, ...) {
  # Koodilohko
  result <- arg1 + arg2  # Esimerkki: kahden luvun yhteenlasku
  return(result)       # Palauttaa tuloksen
}
```

- **function**: Määrittää funktion.
- **arg1, arg2**: Parametrit, jotka otetaan syötteinä.
- **return**: Palauttaa funktion tuloksen.

Funktion luominen ja käyttäminen

Esimerkki 1: Yksinkertainen funktio

```
# Funktion määrittäminen
greet <- function(name) {
  paste("Hello,", name)
}

# Funktion käyttäminen
greet("Alice")  # Tulostaa: "Hello, Alice"
greet("Bob")    # Tulostaa: "Hello, Bob"
```

Esimerkki 2: Laskufunktio

```
# Funktion määrittäminen
add_numbers <- function(a, b) {
  sum <- a + b
```

```
  return(sum)
}

# Funktion käyttäminen
result <- add_numbers(5, 3)
print(result)  # Tulostaa: 8
```

Funktion parametrit

1. Oletusarvot

Funktiolle voidaan määrittää parametreille oletusarvot.

```
# Funktion määrittäminen
multiply <- function(a, b = 2) {
  return(a * b)
}

# Käyttäminen ilman b:tä
print(multiply(5))  # Tulostaa: 10

# Käyttäminen määrittämällä b
print(multiply(5, 3))  # Tulostaa: 15
```

2. Argumenttien nimeäminen

Parametreille voidaan antaa nimet funktiota kutsuttaessa.

```
# Argumenttien nimeäminen
print(multiply(b = 4, a = 3))  # Tulostaa: 12
```

Funktion paluuarvo

Funktion tulos palautetaan yleensä **return()**-komennolla. Ilman return()-komentoa funktio palauttaa viimeisen suoritetun lausekkeen tuloksen.

Esimerkki:

```
# Ilman return
square <- function(x) {
  x * x  # Viimeinen lauseke palautetaan
}

print(square(4))  # Tulostaa: 16
```

Lokaalit ja globaalit muuttujat

Funktion sisällä määritellyt muuttujat ovat **lokaaleja**, eikä niitä voi käyttää funktion ulkopuolella.

Esimerkki:

```
add <- function(a, b) {
  result <- a + b  # Lokaali muuttuja
  return(result)
}

add(3, 4)  # Palauttaa: 7
print(result)  # Virhe: 'result' ei ole olemassa globaalissa ympäristössä
```

Anonyymit funktiot

R tukee myös anonyymejä (ilman nimeä määriteltyjä) funktioita, joita voidaan käyttää erityisesti sisäkkäisten laskentojen yhteydessä.

Esimerkki:

```
# Anonyymi funktio
numbers <- c(1, 2, 3, 4, 5)

# Kerrotaan jokainen luku kahdella
doubled <- sapply(numbers, function(x) x * 2)
print(doubled)  # Tulostaa: [1]  2  4  6  8 10
```

Sisäänrakennetut funktiot

R sisältää monia valmiita funktioita, kuten:

- **Matematiikka**: mean(), sum(), prod(), sqrt()
- **Tekstinkäsittely**: paste(), substr(), toupper(), tolower()

- **Loogiset**: ifelse(), any(), all()
- **Data-analyysi**: aggregate(), apply(), sapply(), tapply()

Soveltaminen data.frameissä

Funktiot ovat erityisen hyödyllisiä toistuvissa operaatioissa, kuten data-analyysissä.

Esimerkki: Keskiarvon laskeminen riveittäin

```
# Dataframe
df <- data.frame(
  Math = c(90, 85, 88),
  Science = c(92, 80, 85),
  History = c(88, 87, 90)
)

# Sovella funktiota riveihin
row_means <- apply(df, 1, mean)
print(row_means)
# Tulostaa: [1] 90.00 84.00 87.67
```

Käytännön esimerkkejä

Esimerkki 1: Fahrenheit Celsius-asteiksi

```
# Fahrenheit to Celsius
fahrenheit_to_celsius <- function(f) {
  c <- (f - 32) * 5 / 9
  return(c)
}

print(fahrenheit_to_celsius(100))  # Tulostaa: 37.77778
```

Esimerkki 2: Ryhmän keskiarvojen laskenta

```
# Ryhmän keskiarvo
group_means <- function(data, group_col, value_col) {
  library(dplyr)
  data %>%
    group_by(.data[[group_col]]) %>%
    summarise(mean_value = mean(.data[[value_col]], na.rm = TRUE))
}

# Esimerkkidata
df <- data.frame(
  Group = c("A", "A", "B", "B"),
  Value = c(10, 20, 30, 40)
)

group_means(df, "Group", "Value")
# Tulostaa:
# # A tibble: 2 × 2
#   Group mean_value
#   <chr>     <dbl>
# 1 A            15
# 2 B            35
```

Hyviä käytäntöjä

1. **Nimeä funktiot selkeästi**: Käytä kuvaavia nimiä, jotka kertovat, mitä funktio tekee.
    - Esimerkki: calculate_total() on parempi kuin calc().
2. **Dokumentoi funktio**: Lisää kommentteja parametrien ja toiminnan selventämiseksi.
3. **Käytä oletusarvoja**: Aseta oletusarvot, kun se on mahdollista, käyttäjäystävällisyyden parantamiseksi.
4. **Testaa funktio**: Testaa funktiota erilaisilla syötteillä varmistaaksesi sen toiminnan.

Datamanipulaatio R-kielessä

Mikä on datamanipulaatio?

Datamanipulaatio tarkoittaa datan muokkaamista, suodattamista ja järjestämistä analyysia varten. R tarjoaa useita tehokkaita työkaluja ja paketteja, kuten **base R** ja **dplyr**, joiden avulla datan käsittely on suoraviivaista.

1. Perustoiminnot base R:llä

1.1 Sarakkeiden ja rivien käsittely

Sarakkeen valitseminen

```
# Dataframe-esimerkki
df <- data.frame(
  Name = c("Alice", "Bob", "Charlie"),
  Age = c(25, 30, 35),
  Score = c(80, 90, 85)
)

df$Name  # Palauttaa sarakkeen "Name"
df[, "Age"]  # Vaihtoehtoinen tapa valita sarake
```

Rivien valitseminen

```
df[1, ]  # Palauttaa ensimmäisen rivin
df[2:3, ]  # Palauttaa rivit 2 ja 3
```

Rivien ja sarakkeiden poistaminen

```
df <- df[-1, ]  # Poistaa ensimmäisen rivin
df <- df[, -2]  # Poistaa toisen sarakkeen
```

1.2 Suodattaminen

```
# Valitse henkilöt, joiden ikä on yli 25
subset_df <- df[df$Age > 25, ]
print(subset_df)
```

1.3 Sarakkeen lisääminen tai muokkaaminen

```
# Lisää uusi sarake
df$Category <- c("A", "B", "A")

# Muokkaa olemassa olevaa saraketta
df$Score <- df$Score + 5
```

1.4 Tietojen järjestäminen

```
# Järjestä iän mukaan nousevasti
df_sorted <- df[order(df$Age), ]

# Järjestä useamman sarakkeen mukaan
df_sorted <- df[order(df$Category, -df$Score), ]
```

2. Datamanipulaatio dplyr-paketilla

Mikä on dplyr?

dplyr on suosittu paketti, joka tarjoaa intuitiivisen tavan datan manipulointiin. Tärkeimmät funktiot ovat:

- **filter()**: Rivien suodattaminen
- **select()**: Sarakkeiden valinta
- **mutate()**: Sarakkeiden lisääminen tai muokkaaminen
- **arrange()**: Rivien järjestäminen
- **summarise()** ja **group_by()**: Yhteenvedot ryhmien mukaan

Asenna paketti, jos sitä ei ole vielä asennettu:

```
install.packages("dplyr")
library(dplyr)
```

2.1 Rivien suodattaminen: filter()

```
# Valitse henkilöt, joiden ikä on yli 25
df_filtered <- filter(df, Age > 25)

# Valitse usean ehdon perusteella
```

```
df_filtered <- filter(df, Age > 25 & Score > 80)
```

2.2 Sarakkeiden valinta: select()

```
# Valitse vain Name ja Score -sarakkeet
df_selected <- select(df, Name, Score)

# Valitse kaikki paitsi Age
df_selected <- select(df, -Age)
```

2.3 Sarakkeiden lisääminen tai muokkaaminen: mutate()

```
# Lisää uusi sarake
df <- mutate(df, AdjustedScore = Score * 1.1)

# Muokkaa olemassa olevaa saraketta
df <- mutate(df, Score = Score + 5)
```

2.4 Rivien järjestäminen: arrange()

```
# Järjestä Score-sarakkeen mukaan nousevasti
df <- arrange(df, Score)

# Järjestä laskevasti
df <- arrange(df, desc(Score))
```

2.5 Ryhmittely ja yhteenvedot: group_by() ja summarise()

```
# Ryhmittele Categoryn mukaan ja laske keskiarvo Score:sta
df_grouped <- df %>%
  group_by(Category) %>%
  summarise(AverageScore = mean(Score))

# Laske useampia yhteenvedon mittareita
df_grouped <- df %>%
  group_by(Category) %>%
  summarise(
    AverageScore = mean(Score),
    TotalScore = sum(Score)
  )
```

---

3. Yhdistely ja muotoilu

3.1 Dataframien yhdistäminen

Riveittäin yhdistäminen: rbind()

```
df1 <- data.frame(Name = c("Alice", "Bob"), Age = c(25, 30))
df2 <- data.frame(Name = c("Charlie", "David"), Age = c(35, 40))

df_combined <- rbind(df1, df2)
```

Sarakkeittain yhdistäminen: cbind()

```
df1 <- data.frame(Name = c("Alice", "Bob"))
df2 <- data.frame(Age = c(25, 30))

df_combined <- cbind(df1, df2)
```

Yhdistäminen avainarvon perusteella: merge()

```
df1 <- data.frame(ID = c(1, 2), Name = c("Alice", "Bob"))
df2 <- data.frame(ID = c(1, 2), Score = c(80, 90))

df_combined <- merge(df1, df2, by = "ID")
```

3.2 Pitkä ja leveä muoto

Muunna leveä muoto pitkäksi: pivot_longer()

```
library(tidyr)

df <- data.frame(
  Name = c("Alice", "Bob"),
  Math = c(90, 85),
  Science = c(92, 80)
)
```

```
df_long <- pivot_longer(df, cols = c("Math", "Science"), names_to = "Subject", values_to = "Score")
```

Muunna pitkä muoto leveäksi: pivot_wider()

```
df_wide <- pivot_wider(df_long, names_from = Subject, values_from = Score)
```

---

4. Käytännön esimerkkejä

Esimerkki 1: Suodatus ja laskenta

```
# Suodata Score > 80 ja laske keskiarvo
filtered_df <- filter(df, Score > 80)
mean_score <- mean(filtered_df$Score)
print(mean_score)
```

Esimerkki 2: Ryhmittely ja järjestäminen

```
df <- data.frame(
 Category = c("A", "A", "B", "B"),
 Value = c(10, 20, 30, 40)
)

# Ryhmittele Categoryn mukaan ja järjestä tulokset
df_summary <- df %>%
 group_by(Category) %>%
 summarise(Total = sum(Value)) %>%
 arrange(desc(Total))
print(df_summary)
```

Esimerkki 3: Laaja manipulointi

```
# Luo data
df <- data.frame(
 Product = c("A", "B", "C", "A", "B", "C"),
 Month = c("Jan", "Jan", "Jan", "Feb", "Feb", "Feb"),
 Sales = c(100, 200, 150, 120, 220, 180)
)

# Analyysi
result <- df %>%
 group_by(Product) %>%
 summarise(
  TotalSales = sum(Sales),
  AvgSales = mean(Sales)
 ) %>%
 arrange(desc(TotalSales))

print(result)
```

Yhteenveto

Datamanipulaatio R:ssä on tehokasta, erityisesti base R:n ja **dplyr**-paketin avulla. Näitä työkaluja käytetään usein:

- **Base R**: Perustoiminnot, kuten suodatus, lajittelu ja laskenta.
- **dplyr**: Intuitiivinen syntaksi monimutkaisempaan datan käsittelyyn.
- **tidyr**: Tiedon muuntamiseen pitkän ja leveän muodon välillä.

Datavisualisointi R-kielessä

Mikä on datavisualisointi?

Datavisualisointi tarkoittaa datan esittämistä visuaalisessa muodossa, kuten kaavioina ja grafiikoina. Visualisoinnin tavoitteena on havainnollistaa tietoja ja tehdä niistä helposti ymmärrettäviä. R tarjoaa useita työkaluja datavisualisointiin, kuten:

1. **Base R**: Perusgrafiikat
2. **ggplot2**: Tehokas ja joustava visualisointikirjasto
3. **Lattice ja muut kirjastot**: Monimutkaisempia analyysejä varten

---

1. Visualisointi Base R:llä

R sisältää useita sisäänrakennettuja funktioita yksinkertaisten kaavioiden luomiseen.

1.1 Pylväsdiagrammi: barplot()

```
# Data
counts <- c(10, 20, 15)
categories <- c("A", "B", "C")

# Luo pylväsdiagrammi
barplot(counts, names.arg = categories, col = "blue",
    main = "Pylväsdiagrammi", xlab = "Kategoria", ylab = "Määrä")
```

1.2 Histogrammi: hist()

```
# Data
data <- rnorm(1000, mean = 50, sd = 10)

# Luo histogrammi
hist(data, breaks = 20, col = "green",
   main = "Histogrammi", xlab = "Arvot", ylab = "Tiheys")
```

1.3 Hajontakaavio: plot()

```
# Data
x <- 1:10
y <- x^2

# Luo hajontakaavio
plot(x, y, main = "Hajontakaavio", xlab = "x-akseli", ylab = "y-akseli",
   col = "red", pch = 16)
```

1.4 Viivakaavio: lines()

```
# Data
x <- 1:10
y <- x^2

# Luo viivakaavio
plot(x, y, type = "o", col = "blue", main = "Viivakaavio",
   xlab = "x-akseli", ylab = "y-akseli")
```

---

2. Visualisointi ggplot2:lla

Mikä on ggplot2?

ggplot2 on yksi suosituimmista visualisointikirjastoista R:ssä. Se perustuu **"grammar of graphics"** -konseptiin, joka mahdollistaa joustavan ja kerroksittaisen lähestymistavan visualisointiin.

Asenna paketti tarvittaessa:

```
install.packages("ggplot2")
library(ggplot2)
```

2.1 Peruskaavio: ggplot()

Hajontakaavio

```
# Data
df <- data.frame(x = rnorm(100), y = rnorm(100))

# Luo hajontakaavio
ggplot(df, aes(x = x, y = y)) +
 geom_point(color = "blue") +
```

```
 labs(title = "Hajontakaavio", x = "x-akseli", y = "y-akseli")
```

Viivakaavio

```
# Data
df <- data.frame(x = 1:10, y = cumsum(rnorm(10)))

# Luo viivakaavio
ggplot(df, aes(x = x, y = y)) +
 geom_line(color = "red") +
 labs(title = "Viivakaavio", x = "x-akseli", y = "y-akseli")
```

2.2 Pylväsdiagrammi

```
# Data
df <- data.frame(Category = c("A", "B", "C"),
                 Count = c(10, 20, 15))

# Luo pylväsdiagrammi
ggplot(df, aes(x = Category, y = Count, fill = Category)) +
 geom_bar(stat = "identity") +
 labs(title = "Pylväsdiagrammi", x = "Kategoria", y = "Määrä")
```

2.3 Histogrammi

```
# Data
data <- data.frame(Value = rnorm(1000))

# Luo histogrammi
ggplot(data, aes(x = Value)) +
 geom_histogram(binwidth = 5, fill = "green", color = "black") +
 labs(title = "Histogrammi", x = "Arvot", y = "Frekvenssi")
```

2.4 Boxplot

```
# Data
df <- data.frame(
 Category = rep(c("A", "B", "C"), each = 20),
 Value = c(rnorm(20, mean = 5), rnorm(20, mean = 10), rnorm(20, mean = 15))
)

# Luo boxplot
ggplot(df, aes(x = Category, y = Value, fill = Category)) +
 geom_boxplot() +
 labs(title = "Boxplot", x = "Kategoria", y = "Arvot")
```

2.5 Ryhmitelty visualisointi

```
# Data
df <- data.frame(
 Group = rep(c("A", "B"), each = 10),
 Category = rep(c("X", "Y"), times = 10),
 Value = rnorm(20)
)

# Luo ryhmitelty pylväsdiagrammi
ggplot(df, aes(x = Category, y = Value, fill = Group)) +
 geom_bar(stat = "identity", position = "dodge") +
 labs(title = "Ryhmitelty pylväsdiagrammi", x = "Kategoria", y = "Arvot")
```

---

3. Interaktiiviset visualisoinnit

plotly

Voit muuttaa ggplot2-grafiikat interaktiivisiksi käyttämällä **plotly**-pakettia.

```
install.packages("plotly")
library(plotly)

# Luo ggplot2-kaavio
p <- ggplot(df, aes(x = x, y = y)) +
```

```
  geom_point()

# Tee kaaviosta interaktiivinen
ggplotly(p)
```

---

4. Käytännön esimerkkejä

Esimerkki 1: Myyntidata

```
# Data
sales <- data.frame(
  Month = rep(c("Jan", "Feb", "Mar"), each = 3),
  Product = rep(c("A", "B", "C"), times = 3),
  Sales = c(100, 200, 150, 120, 220, 180, 130, 210, 170)
)

# Luo viivakaavio myynnistä
ggplot(sales, aes(x = Month, y = Sales, color = Product, group = Product)) +
  geom_line() +
  geom_point() +
  labs(title = "Myynti kuukausittain", x = "Kuukausi", y = "Myynti")
```

Esimerkki 2: Histogrammi ja tiheyskäyrä

```
# Data
data <- data.frame(Value = rnorm(1000))

# Luo histogrammi ja tiheyskäyrä
ggplot(data, aes(x = Value)) +
  geom_histogram(aes(y = ..density..), binwidth = 1, fill = "blue", alpha = 0.5) +
  geom_density(color = "red") +
  labs(title = "Histogrammi ja tiheyskäyrä", x = "Arvot", y = "Tiheys")
```
